

Journal de Stage

Progression du Projet - Analyse et Prédiction de Churn

Auteur : [Your Name]
Période : [Start Date] - [End Date]
Établissement : ESPRIM
Entreprise : INSITFUL
Tuteur de stage : Elgregba Amira

Année universitaire : 2025 – 2026

Table des matières

1	Semaine 1 : Initialisation et Exploration des Données	2
1.1	Jour 1 : Lancement du projet et configuration de l'environnement	2
1.2	Jour 2 : Analyse exploratoire des données (EDA)	2
1.3	Jour 3 : Visualisation des données	2
1.4	Jour 4 : Prétraitement des données	2
1.5	Jour 5 : Ingénierie des fonctionnalités (Feature Engineering)	2
2	Semaine 2 : Modélisation et Évaluation	3
2.1	Jour 6 : Division des données et premier modèle	3
2.2	Jour 7 : Entraînement du modèle CatBoost	3
2.3	Jour 8 : Optimisation des hyperparamètres	3
2.4	Jour 9 : Évaluation du modèle final	3
2.5	Jour 10 : Sauvegarde du modèle	3
3	Semaine 3 : Interprétabilité et Développement de l'Interface	4
3.1	Jour 11 : Introduction à l'IA Explicable (XAI) avec SHAP	4
3.2	Jour 12 : Implémentation de SHAP	4
3.3	Jour 13 : Développement de l'application Streamlit	4
3.4	Jour 14 : Création de la page "Analyse Globale"	4
3.5	Jour 15 : Visualisations interactives	4
4	Semaine 4 : Finalisation de l'Application et Rapports	5
4.1	Jour 16 : Développement de la page "Diagnostic Client"	5
4.2	Jour 17 : Intégration des explications SHAP	5
4.3	Jour 18 : Amélioration de l'interface utilisateur (UI/UX)	5
4.4	Jour 19 : Rédaction du rapport de stage	5
4.5	Jour 20 : Finalisation et préparation de la soutenance	5

Chapitre 1

Semaine 1 : Initialisation et Exploration des Données

1.1 Jour 1 : Lancement du projet et configuration de l'environnement

Prise en main du projet de prédiction du churn client. L'objectif est d'analyser les données des clients et de développer un modèle pour prédire leur probabilité de départ. Configuration de l'environnement de développement Python, et installation des bibliothèques de base comme Pandas, NumPy, et Scikit-learn.

1.2 Jour 2 : Analyse exploratoire des données (EDA)

Chargement du jeu de données `WA_Fn-UseC_-Telco-Customer-Churn.csv` avec Pandas. Première analyse des dimensions du dataset, des types de données et des valeurs manquantes. Une attention particulière a été portée à la colonne `TotalCharges` qui contient des valeurs manquantes pour les nouveaux clients.

1.3 Jour 3 : Visualisation des données

Utilisation de Matplotlib et Seaborn pour créer des visualisations. Création d'histogrammes pour les variables numériques comme 'tenure' et 'MonthlyCharges', et de diagrammes à barres pour les variables catégorielles comme 'Contract' et 'PaymentMethod'. L'objectif est de comprendre la distribution des données et les relations initiales avec la variable cible 'Churn'.

1.4 Jour 4 : Prétraitement des données

Nettoyage des données. Les valeurs manquantes dans 'TotalCharges' ont été remplacées par zéro, en supposant que les nouveaux clients n'ont pas encore de frais totaux. Conversion des variables catégorielles en formats numériques à l'aide de l'encodage one-hot pour préparer les données pour les modèles de machine learning.

1.5 Jour 5 : Ingénierie des fonctionnalités (Feature Engineering)

Création de nouvelles fonctionnalités pour améliorer la performance du modèle. Par exemple, la variable 'tenure' (ancienneté) a été regroupée en catégories ('TenureGroup') pour mieux capturer les cycles de vie des clients. Finalisation du jeu de données pour la phase de modélisation.

Chapitre 2

Semaine 2 : Modélisation et Évaluation

2.1 Jour 6 : Division des données et premier modèle

Division du jeu de données en ensembles d'entraînement et de test avec la fonction `train_test_split` de Scikit-learn. Entraînement d'un modèle de régression logistique comme référence de base pour évaluer les performances des modèles plus complexes.

2.2 Jour 7 : Entraînement du modèle CatBoost

Exploration et entraînement d'un modèle plus avancé, CatBoost. Ce modèle est particulièrement efficace car il gère nativement les variables catégorielles, ce qui simplifie le prétraitement. Le modèle a été entraîné sur l'ensemble de données d'entraînement.

2.3 Jour 8 : Optimisation des hyperparamètres

Utilisation de techniques comme `GridSearchCV` pour trouver les meilleurs hyperparamètres pour le modèle CatBoost. L'objectif est d'améliorer la précision et la capacité de généralisation du modèle en testant différentes combinaisons de paramètres comme la profondeur des arbres et le taux d'apprentissage.

2.4 Jour 9 : Évaluation du modèle final

Évaluation du modèle CatBoost optimisé sur l'ensemble de test. Les métriques de performance comme l'exactitude (accuracy), la précision, le rappel (recall) et le score F1 ont été calculées. Le modèle a montré des performances prometteuses par rapport au modèle de base.

2.5 Jour 10 : Sauvegarde du modèle

Sauvegarde du modèle entraîné et optimisé à l'aide de 'joblib'. Cela permet de réutiliser le modèle dans l'application Streamlit sans avoir à le ré-entraîner à chaque fois, ce qui est crucial pour le déploiement.

Chapitre 3

Semaine 3 : Interprétabilité et Développement de l'Interface

3.1 Jour 11 : Introduction à l'IA Explicable (XAI) avec SHAP

Recherche sur l'importance de l'interprétabilité des modèles. Découverte de la bibliothèque SHAP (SHapley Additive exPlanations) qui permet d'expliquer les prédictions de n'importe quel modèle de machine learning.

3.2 Jour 12 : Implémentation de SHAP

Création d'un 'TreeExplainer' pour le modèle CatBoost. Calcul des valeurs SHAP pour l'ensemble des données de test. Ces valeurs permettent de quantifier la contribution de chaque caractéristique à la prédiction pour chaque client.

3.3 Jour 13 : Développement de l'application Streamlit

Début du développement de l'interface utilisateur avec Streamlit. Création du fichier principal 'app.py', mise en place de la structure de base, du titre, et des fonctions pour charger le modèle et les données de manière efficace en utilisant le cache de Streamlit.

3.4 Jour 14 : Création de la page "Analyse Globale"

Développement de la première page de l'application : un tableau de bord pour l'analyse globale du churn. Ajout de filtres interactifs pour permettre aux utilisateurs d'explorer les données en fonction du type de contrat, du service Internet, etc.

3.5 Jour 15 : Visualisations interactives

Intégration de graphiques interactifs (avec Plotly Express) dans la page d'analyse globale. Création de graphiques montrant le taux de churn par groupe d'ancienneté et d'autres visualisations pertinentes pour aider à comprendre les tendances générales.

Chapitre 4

Semaine 4 : Finalisation de l'Application et Rapports

4.1 Jour 16 : Développement de la page "Diagnostic Client"

Création de la deuxième fonctionnalité principale de l'application : une page pour le diagnostic individuel des clients. Ajout d'un sélecteur pour choisir un 'customerID' et afficher les détails de ce client.

4.2 Jour 17 : Intégration des explications SHAP

Intégration des visualisations SHAP dans la page de diagnostic. Affichage d'un graphique "force plot" de SHAP pour le client sélectionné, montrant visuellement les facteurs qui augmentent ou diminuent sa probabilité de churn.

4.3 Jour 18 : Amélioration de l'interface utilisateur (UI/UX)

Travail sur le style et l'ergonomie de l'application. Ajout de CSS personnalisé pour une apparence plus professionnelle, amélioration de la disposition des éléments et ajout de textes explicatifs pour guider l'utilisateur.

4.4 Jour 19 : Rédaction du rapport de stage

Début de la rédaction du rapport de stage ('report.tex'). Documentation de toutes les étapes du projet, de l'analyse initiale des données à la création de l'application, en passant par la modélisation et l'interprétabilité.

4.5 Jour 20 : Finalisation et préparation de la soutenance

Relecture finale du code, de l'application et du rapport. Préparation d'une présentation pour la soutenance de stage, résumant le travail accompli, les défis rencontrés et les résultats obtenus. Nettoyage du dépôt Git et finalisation de la documentation.